Laboratorio 2 – Diseñando el problema de IA

De una necesidad jurídica a su propio clasificador

1. ¿De qué se trata?

En el laboratorio guiado vimos cómo un programa aprende a distinguir tutelas, derechos de petición y demandas a partir de ejemplos que **nosotros** le dimos. Ahora el reto es suyo:

> ***Piensen en una tarea repetitiva con documentos que se podría ayudar a organizar, definan ustedes las categorías y los criterios, construyan los ejemplos y entrenen su primer clasificador.***

En este laboratorio **no se les evalúa por qué tan alto es el porcentaje de acierto**, sino por qué tan bien diseñaron el problema, qué tan claros son sus criterios jurídicos y qué tan buenos son sus ejemplos.

2. Lo que deben entregar al final de la sesión

1. **Documento de diseño**
2. **Archivo con el dataset inicial**
3. **Notebook con el primer clasificador entrenado** con sus propias categorías

3. Documento de diseño

Responda cada punto con claridad. **No se necesita lenguaje técnico.**

3.1 El problema

¿Qué tarea con documentos quieren ayudar a automatizar? Descríbanla en 3 a 5 líneas.

3.2 El usuario

¿Quién usaría este clasificador y para qué? Expliquen **qué haría esa persona con el resultado**.

3.3 Las categorías

- **Mínimo:** 3 categorías.
- **Máximo 5** categorías en esta fase.

Cada categoría debe ser **distinta de las demás** y un documento debe poder pertenecer, en principio, a una sola.

3.4 Criterio de clasificación

Para cada categoría respondan:

> ***¿Qué hace que un documento pertenezca a esta categoría?***

Pueden usar una tabla como esta:

Categoría	Criterio: ¿qué hace que un documento pertenezca a ella?	¿Qué NO es? (casos que se confunden)
Ejemplo: Tutela	Busca la protección de derechos fundamentales mediante acción de tutela	Una demanda ordinaria que menciona derechos fundamentales de pasada
Ejemplo: Derecho de petición	Solicitud dirigida a una autoridad o particular en ejercicio del derecho de petición	Una tutela que contiene una solicitud previa
Su categoría 1		
Su categoría 2		
Su categoría 3		

3.5 Dataset inicial

Describan en un párrafo corto:

- Cuántos documentos tiene cada categoría.
- De dónde salieron.

3.6 Decisiones de limpieza

¿Qué deberían hacerle al texto antes de entrenar y **por qué**?.

3.7 Justificación de representatividad

Expliquen en 5 a 8 líneas **por qué estos documentos representan el problema real**. Algunas preguntas guía:

- ¿Los ejemplos son parecidos a los documentos que el usuario de verdad recibiría?
- ¿Hay variedad de estilos de redacción y de longitud?
- ¿Qué casos reales importantes NO quedaron cubiertos?
- ¿Podría haber sesgo? (por ejemplo, que todos los ejemplos vengan de una sola entidad o de un solo estilo de abogado).

4. Construcción del dataset

4.1 Tamaño mínimo

15 documentos por categoría.

Categorías	Documentos mínimos
3	45

Categorías	Documentos mínimos
4	60
5	75

Intenten que todas las categorías tengan **aproximadamente la misma cantidad**.

4.2 ¿Qué se considera un "documento"?

No tienen que ser documentos completos. Pueden ser fragmentos de uno o dos párrafos.

4.3 Fuentes permitidas

- Fragmentos escritos por ustedes.
- Casos **sintetizados** a partir de situaciones que conocen.
- Textos jurídicos reales **previamente anonimizados** (sin nombres, cédulas, direcciones, teléfonos, radicados ni datos de personas reales).
- Textos generados con IA como ayuda, **siempre revisados por ustedes**.

4.4 Formato del archivo

Guarden el dataset como una tabla con estas columnas:

Columna	Qué contiene	Ejemplo
`id`	Número consecutivo	1
`texto`	El fragmento del documento	"Por medio de la presente solicito…"
`categoria`	Una de sus categorías (escrita siempre igual)	Derecho de petición
`origen`	`propio`, `real_anonimizado`, `sintetizado` o `ia_revisado`	ia_revisado
`revisado_por`	Quién aprobó la etiqueta	María

5. Ejercicio de calidad antes de entrenar

Antes de pasar al modelo, hagan esta revisión cruzada:

1. Cada integrante toma **5 documentos que no escribió** y los clasifica usando solo la tabla de criterios.
2. Comparen con la clasificación original. ¿Cuántos coinciden?
3. Por cada desacuerdo, decidan: ¿el documento está mal clasificado, el criterio es ambiguo o el documento es realmente un caso fronterizo?
4. Corrijan lo que sea necesario y anoten en el documento de diseño qué aprendieron.

6. Entrenamiento del primer clasificador

Usen como base el notebook del laboratorio guiado. Solo cambian el origen de los datos (su archivo) y los nombres de sus categorías. Para esto pueden usar como apoyo las diferentes herramientas de inteligencia artificial.

Preguntas que deben responder por escrito (máximo 10 líneas en total):

1. ¿En qué categoría se equivoca más el modelo? ¿Por qué creen que ocurre?
2. Miren los documentos que el modelo clasificó mal: ¿el error es del modelo, de la clasificación o de un criterio ambiguo?
3. Si este clasificador fuera usado mañana por el usuario que definieron, ¿qué podría salir mal y qué revisión humana pondrían?